


陈昕宇

中国，北京 chenxinyu20040529@gmail.com +86 18911827529



教育经历

北京大学，元培学院，通用人工智能实验班

2022 年 9 月 - 2026 年 7 月

- 班级：**通用人工智能实验班（师从国内外知名人工智能朱松纯教授）
- 专业：**人工智能
- GPA：**3.565/4.0 | 85/100（前三年：3.667/4.0 | 86.7/100）
- 核心课程：**机器学习（91）、人工智能数学基础（90）、多智能体系统（94）、计算机视觉导论（93）、人工智能系统实践 I（96）、人工智能系统实践 II（97）、认知与推理（90.5）、深度学习与自然语言处理（93）

北京一零一中学

2016 年 9 月 - 2022 年 7 月

- 高考取得北京市前 20。

北京大学，计算机学院，博士生

计划于 2026 年 9 月入学，2031 年 7 月毕业

- 博士生导师：**王腾蛟，长江学者，北京大学计算社会科学研究中心主任，北京大学（青岛）计算社会科学研究院院长，博士生导师。

PAIR Lab | 实验室成员

北京大学对齐与交互研究实验室，聚焦强化学习、多智能体系统、博弈论与 AGI 价值对齐。

BAAI 智源研究院 | 实习生

国内领先的非营利性 AI 研究机构，聚焦大模型、具身智能、AI 安全与开源基础设施。

英语能力

CET-4:

605（2022 年 12 月获得）

CET-6: 664（2023 年 6 月获得）

TOEFL:

107（2023 年 10 月获得）

语言与技能

- 编程语言：**C++、C、CUDA、Python
- 自然语言：**中文（母语）、英语（熟练）
- 曾于 2025 年 1 月 - 2025 年 5 月赴新加坡国立大学交换 1 学期，适应全英文授课。
- 曾于 2025 年 12 月赴美国圣迭戈参加 NeurIPS 2025 会议，具备英文学术交流能力。

奖项

- **2024:** 兴正德奖学金 (5000 元)
- **2023:** 北京大学社会工作奖
- **2022:** 林护奖学金 (50000 元)

科研经历

法律人工智能，北京大学 / 北京通用人工智能研究院	2024 年 3 月 - 2024 年 6 月
• 构建用于法律案件关键要素结构化抽取的数据集。 • 验证了基于该数据集微调的大语言模型能够有效抽取法律案件关键特征，用于支持基于模型的案件判断。	
大语言模型安全评测，PAIR Lab	2024 年 9 月 - 2024 年 11 月
• 探索大语言模型 DNA 范式：一种不依赖特定危害类别、可扩展的综合安全评测方法。	
大语言模型与视觉语言模型对齐，PAIR Lab	2024 年 6 月 - 2025 年 5 月
• 参与 <i>Align Anything</i> 框架开发，包括训练代码、交互式终端和数据集建设。 • 开发 Beaver-V 偏好数据集，以提升视觉语言模型的安全性与有用性。 • 设计 Safe RLHF-V 算法，用于平衡视觉语言模型的安全性与有用性。	
基于大语言模型的社会关系理解，北京大学 / BIGAI	2024 年 12 月 - 2025 年 5 月
• 与孔繁祺合作，探索新的对抗式模型生成方法，以增强大语言模型检测机器人的能力。	
LLM Math Agent	2025 年 9 月 - 至今
• 致力于构建基于步骤拆解和细粒度审查的自动化数学证明 verifier。	
Multi Agent LLM	2025 年 9 月 - 至今
• 致力于使用 multi agent 强化学习方法提升模型长上下文能力。	
LLM LoRA Memory	2026 年 5 月 - 至今
• 致力于开发新方法以切实提升 test time training 的模型能力。	
AI for Perovskite	2025 年 9 月 - 至今
• 致力于使用微调的预训练分子大模型对钙钛矿掺杂分子的 delta PCE 进行预测。	
AI for Cryo-ET Reconstruction	2025 年 9 月 - 至今
• 致力于构建基于变分推断的 Cryo-ET 重建范式，从理论和实验两层面证明其可用性和对社区的启发性。 • 推出了系列工作 CryoGEN、CryoGEN-II、CryoWGEN，完成了博客页面 Cryo-ET blog Xinyu Chen 和知识库 Open Cryo-ET。	

项目经历

Align-Anything

repo

项目功能 PKU-Alignment 团队开源的全模态大模型对齐框架，面向 LLM、VLM 及 any-to-any 多模态模型的后训练与对齐，支持文本、图像、音频、视频等多种输入输出模态。

个人贡献 负责实现多个大语言模型对齐算法，包括 ORPO、SimPO、KTO 以及 PEFT 算法；主导交互式终端开发；合作参与 [align-anything dataset](#) 建设。

Safe-RLHF-V / BeaverTails-V

repo

项目功能 将传统 Safe RLHF 扩展到视觉-语言场景，通过分别建模 helpfulness reward 与 safety cost，并结合拉格朗日约束优化，在提升模型有用性的同时控制安全风险；同时提出 BeaverTails-V 多模态安全偏好数据集与 Beaver-Guard-V 多级安全防护机制，用于支持 MLLM 的安全训练、过滤与评估。

个人贡献 作为主要贡献者实现 Safe-RLHF-V 相关训练、评测代码；作为主要贡献者构建多模态偏好数据集 BeaverTails-V。

AgentMind

Agent 平台

项目功能 数据收集、知识库 RAG 建图、深度研究全流程 agent 平台；支持多源数据采集、知识库 RAG 与实体增强建图、深度研究工作流和结构化报告生成，并服务于中光学的光学大模型对话平台部署迁移。

个人贡献 作为主要贡献者负责深度研究模块、RAG 推理加速模块和相关 LLM tools、skills 的开发。

本科毕业论文：基于大语言模型的多模态语义压缩方法实现

本科毕业论文

项目功能 聚焦大语言模型场景下的多模态语义压缩，设计并实现面向长文档与图文混排数据的智能压缩与检索增强系统；通过任务感知图式生成、上下文感知图文融合和可回溯层级索引，提升知识库语义密度、检索效率与生成结果可信度。

个人贡献 论文通过答辩，获得“优秀”评价。

竞赛经历

第九届全国青少年人工智能创新创业大赛创新赛道

2024 年 12 月

“智驰”项目队长，一等奖 | 团队共 5 人

项目功能 提出基于集成学习的模型，用于预测第三磨牙与下颌管之间的空间关系，超过专业牙科专家诊断能力；系统可辅助临床牙医进行第三磨牙手术术前诊断。

个人贡献 作为领队前往深圳宣讲项目，顺利完成项目答辩。

科研产出

Safe RLHF-V: Safe Reinforcement Learning from Multi-modal Human Feedback

NeurIPS 2025

作者: Jiaming Ji, Xinyu Chen, Rui Pan, Conghui Zhang, Han Zhu, Jiahao Li, Donghai Hong, Boyuan Chen, Jiayi Zhou, Kaile Wang, Juntao Dai, Chi-Min Chan, Yida Tang, Sirui Han, Yike Guo, Yaodong Yang.

简介: Safe RLHF-V 是一篇面向多模态大语言模型安全对齐的研究工作，旨在解决 MLLM 在图文输入场景下可能产生有害响应、且传统单一偏好 RLHF 难以同时兼顾 helpfulness 与 safety 的问题。论文提出了包括 BeaverTails-V、Beaver-Guard-V 以及基于 reward/cost 解耦建模和拉格朗日约束优化的 Safe RLHF-V 算法。

个人贡献: 作为共同一作，负责大部分代码实现、数据集构建和评测工作。

CryoGEN-II: Cryogenic Electron Tomography Reconstruction via Generative Network

CVPR 2026 Workshop

作者: Yunfei Teng, Xinyu Chen, He Zhang, Qiwei Ye, Yulei Hung, Sha Hu.

简介: CryoGEN-II 是一项面向冷冻电子断层成像 (Cryo-ET) 三维重建的生成式方法研究，旨在缓解有限倾角采集带来的 missing wedge 问题及其导致的 Z 轴拉伸、伪影和结构失真。论文从变分推断视角重新理解 Cryo-ET 重建任务，并引入 latent-space Sharpness-Aware Minimization (SAM) 以提升训练稳定性和重建鲁棒性。

个人贡献: 作为共同一作，负责 In-situ Cryo-ET 算法实现和实验。

CryoWGEN: Cryogenic Electron Tomography Reconstruction via Wasserstein Generative Network

正在投稿

作者: Xinyu Chen, Zhichao Chen, Hongwang Xiao, Xi Chen, Yuxuan Xiong, Yan Wang, Zhouchen Lin, Yunfei Teng.

简介: 提出 CryoWGEN，一种新的生成式重建框架，将 missing-wedge 补全重新表述为变分推断问题，并进一步引入最优传输思想，使模型能够学习有效恢复各向同性分辨率的后验分布，同时保持结构保真度与可解释性。

个人贡献: 作为第一作者，负责全部算法实现、In-situ Cryo-ET 实验和部分论文撰写。

EVIA: Entropic Variational Inference Auto-encoding

UAI 2026

作者: Yunfei Teng, Zhichao Chen, Xinyu Chen, Lulu Tang, Sixin Zhang, Zhouchen Lin.

简介: 调研 EVIA：一种结合熵正则化、最优传输与变分推断的自编码生成框架，将 WAE 中的确定性潜变量映射扩展为分布级后验建模，并通过 SGLD 采样提升训练稳定性与潜空间对齐效果，在后验估计、图像生成和图像修复任务上取得优于 VAE/AAE/WAE 的表现。

个人贡献: 负责实验效果改进和实验部分的论文写作。

作者: Fanqi Kong, Xiaoyuan Zhang, Xinyu Chen, Yaodong Yang, Song-Chun Zhu, Xue Feng.

简介: EvoBot 是一种基于大语言模型的社会媒体智能体框架,旨在生成更符合真实用户画像与社交关系背景的人类式内容。论文提出了一个对抗学习范式:先使用真实社交媒体数据进行监督微调,再引入共同演化的社交机器人检测器作为动态反馈源,通过 DPO 优化 EvoBot 的生成结果。

个人贡献: 负责部分实验、论文写作和论文图表优化。

SIV-Bench: A Video Benchmark for Social Interaction Understanding and Reasoning

ACL 2026

作者: Fanqi Kong, Weiqin Zu, Xinyu Chen, Yaodong Yang, Song-Chun Zhu, Xue Feng.

简介: SIV-Bench 是一个面向多模态大模型社会交互理解与推理能力评测的视频基准,旨在系统评估模型是否能够理解真实场景中的多人互动、社会关系、情绪意图与后续行为变化。该基准基于社会关系理论构建,将社会交互能力划分为社会场景理解、社会状态推理和社会动态预测三个层次。

个人贡献: 参与数据收集部分和评测部分。

Reinforced Self-play for Long-Context Understanding

正在准备

作者: Xinyu Chen, Yiding Wang, Shijia Kang, Muhan Zhang.

简介: Long-context Zero Reasoner (LZR) 是一种面向长上下文大模型能力提升的自博弈强化学习框架。该方法无需人工标注数据,通过自动生成并求解 Needle-in-a-Haystack 长上下文任务,构建可自验证的训练反馈闭环,使模型在百万级上下文中持续提升信息定位与推理能力,并有效缓解“lost-in-the-middle”问题。

个人贡献: 负责实验代码实现、评测和论文撰写工作。

GraphVerify: A Dependency-Aware Multi-Agent Verifier for Natural Language Proofs

正在准备

作者: Haotong Yang, Xinyu Chen, Huijun Yu, Wenkai Yu, Songshen He, Siqi Yang, Zhouchen Lin, Muhan Zhang.

简介: GraphVerify 是一种面向数学自然语言证明验证的多智能体框架,旨在解决传统整体式 proof checking 难以定位细粒度逻辑错误、且容易受模型幻觉影响的问题。该方法将自然语言证明解析为 Proof Dependency Graphs,并调度多个专门化 agent 对每个推理步骤进行逐步验证,同时结合外部工具提升校验可靠性。

个人贡献: 负责构建项目代码、实验和论文撰写工作。

Transfer learning discovery of molecular modulators for perovskite solar cells

正在准备

作者: Haoming Yan, Xinyu Chen, Yanran Wang, Zhangyuchang Lu, Zhengchao Luo, Weizheng Huang, Tianyu Huang, Hongshuai Wang, Peng Chen, Ziming Chen, Yuzhi Zhang, Weijie Sun, Jinzhuo Wang, Rui Zhu, Lichen Zhao.

简介: 基于迁移学习的钙钛矿太阳能电池分子调节剂筛选:针对钙钛矿太阳能电池分子调节剂发现中化学空间庞大、实验筛选成本高且数据稀缺的问题,构建了基于预训练深度神经网络的化学知识引导迁移学习框架,用于预测分子调节剂对器件光电转换效率(PCE)及效率提升幅度(Δ PCE)的影响,并对 79,043 个商业可得分子进行低成本、高通量虚拟筛选。

个人贡献: 负责项目代码实现和部分实验论文撰写。

报告

CryoGEN-II：基于生成网络的冷冻电子断层扫描重建_智源社区

介绍和科普冷冻电镜的历史、主要流程和传统方法，并进而介绍宣传 CryoGEN / CryoGEN-II 系列工作，以及将 Cryo-ET 重建理解为变分推断的全新思路。

博客

Cryo-ET blog

Cryo-ET 重建方法综述，梳理冷冻电子断层成像工作流、WBP/SIRT 经典算法，以及 IsoNet、DeepDeWedge、CryoGEN 等深度学习方法，重点关注 missing wedge 校正、去噪与三维 tomogram 重建问题。